

Análisis Exploratorio y Comparativo de Técnicas de Reconocimiento de Patrones para la Caracterización de Indicadores de Insuficiencia Renal Crónica

1st Valentina Arce España
Departamento de Ingeniería Electrónica
Pontificia Universidad Javeriana
Bogotá, D.C., Colombia
arce_v@javeriana.edu.co

2nd Sergio A. Herrera Castro
Departamento de Ingeniería Electrónica
Pontificia Universidad Javeriana
Bogotá, D.C., Colombia
se-herrera@javeriana.edu.co

Abstract—Chronic kidney disease (CKD) represents a growing challenge for global public health, characterized by the progressive deterioration of renal function, often remaining asymptomatic during its early stages. This article presents a comparative analysis of pattern recognition techniques applied to a clinical dataset for CKD diagnosis. The study encompasses an exploration of the statistical structure and geometric separability of the data, as well as the implementation of parametric methods (QDA, LDA) and non-parametric methods (k-NN, Parzen KDE, RBF SVM, Multilayer Perceptron). The results demonstrate that, given the strong geometric heteroscedasticity of the clinical problem, nonlinear architectures such as deep MLPs and RBF SVMs maximize both diagnostic accuracy and clinical interpretability, providing a robust decision-making framework for early diagnosis.

Index Terms—Pattern recognition, chronic kidney disease, clinical biomarkers, nonparametric estimation, multilayer perceptron, support vector machines.

I. INTRODUCCIÓN

La insuficiencia renal crónica (IRC) es la pérdida gradual y progresiva de la capacidad de los riñones para filtrar los desechos y el exceso de líquidos de la sangre. Al ser un proceso degenerativo, el tejido sano es reemplazado por fibrosis, disminuyendo la tasa de filtración glomerular. El daño suele ser acumulativo y silencioso en sus primeras etapas, siendo la diabetes mellitus y la hipertensión arterial sus principales factores desencadenantes fisiológicos.

La detección temprana es crucial, pero se ve limitada por la complejidad y variabilidad de los biomarcadores clínicos. En este contexto, el presente proyecto propone la aplicación de los fundamentos del reconocimiento de patrones para evaluar la separabilidad estadística de pacientes sanos y diagnosticados. El objetivo principal es contrastar la efectividad empírica y teórica de arquitecturas paramétricas y no paramétricas, sentando las bases de una herramienta de diagnóstico precoz basada en el análisis riguroso de características clínicas y hematológicas.

II. METODOLOGÍA

A. Conjunto de Datos y Preprocesamiento

El conjunto de datos de insuficiencia renal crónica (IRC) se obtuvo del *UCI Machine Learning Repository* mediante su API oficial en Python. Consta de 400 instancias con 24 características y una etiqueta binaria de clase: CKD ($n = 250$) y notCKD ($n = 150$). Las variables incluyen once numéricas continuas como la edad, presión arterial, glucosa sérica, urea, creatinina sérica, sodio, potasio, hemoglobina, volumen celular empacado, leucocitos y eritrocitos; tres ordinales, que incluyen la gravedad específica, albuminuria, y la glucosa, y por último, diez nominales binarias: hipertensión, diabetes, anemia, entre otras.

El preprocesamiento se diseñó en función de los hallazgos del análisis exploratorio. Las variables de retención de desechos (*sc*, *bu*, *bgr*) presentaban asimetría positiva extrema, por lo que se les aplicó una transformación logarítmica (ecuación 1) para estabilizar su varianza. Para el resto de variables numéricas se aplicó winsorización en el rango del percentil 1 al 99 para contener valores atípicos extremos sin eliminar observaciones. Las variables nominales y ordinales fueron codificadas numéricamente mediante `LabelEncoder`. Finalmente, los valores faltantes, que afectaban a todas las variables y alcanzaban hasta el 38% en el conteo de glóbulos rojos, se imputaron con un KNN-Imputer de $k = 5$ vecinos con pesos por distancia inversa, por ser el único método que preserva las relaciones no lineales locales sin asumir una distribución paramétrica subyacente.

$$x' = \log(1 + x) \quad (1)$$

B. Análisis Exploratorio y Distribución Espacial

La exploración estadística se estructuró en tres etapas.

1) *Análisis Univariado*: Se trazaron histogramas con estimadores KDE por clase y se ejecutaron las siguientes tres pruebas de normalidad sobre cada variable numérica: Shapiro-Wilk, D'Agostino-Pearson y Kolmogorov-Smirnov. Todas las pruebas rechazaron la hipótesis nula de normalidad ($p \ll 0.05$), descartando el uso de imputación por media.




Fig. 1. Elipses de covarianza por clase ($1\sigma, 2\sigma, 3\sigma$) para pares de variables numéricas seleccionadas. La asimetría geométrica entre las elipses de CKD (rojo) y notCKD (verde) evidencia la heterocedasticidad

2) *Análisis bivariado y matrices de covarianza* : Se calcularon las matrices de correlación de Pearson, Spearman y Kendall para detectar la multicolinealidad. Las variables hematológicas *hemo*, *pcv* y *rbcc* mostraron correlaciones superiores a 0.85 entre sí. El cálculo de las matrices de covarianza por clase $\hat{\Sigma}_{ckd}$ y $\hat{\Sigma}_{notckd}$ reveló el hallazgo central del análisis exploratorio: la clase sana forma un clúster compacto con varianza mínima, mientras que la clase enferma tiende a presentar una dispersión mucho más amplia y covarianzas más complejas. Esta heterocedasticidad, es decir $\hat{\Sigma}_{ckd} \neq \hat{\Sigma}_{notckd}$, condicionó de forma directa la elección de los clasificadores.

C. Fisher Discriminant Ratio

Para cuantificar el poder discriminante individual de cada variable se calculó:

$$FDR_j = \frac{(\mu_{1j} - \mu_{2j})^2}{\sigma_{1j}^2 + \sigma_{2j}^2} \quad (2)$$

Las cinco variables con mayor FDR fueron hemoglobina (*hemo*), volumen celular empaçado (*pcv*), conteo de glóbulos rojos (*rbcc*), creatinina sérica (*sc*) y urea (*bu*). Estas variables, junto con otras numéricas, categóricas y ordinales de alta prevalencia diferencial, conformaron el espacio de 18 variables clave empleado en la Fase III.

D. Reducción de Dimensionalidad

Previo a los clasificadores paramétricos se aplicó PCA sobre las 11 variables numéricas estandarizadas. Esta decisión responde a tres problemas estructurales identificados en el EDA: (1) la multicolinealidad extrema hace singular a $\hat{\Sigma}_{c_i}$ e impide su inversión estable; (2) la muestra disponible no supera $d^2 = 576$ observaciones requeridas para estimar confiablemente una covarianza de 24 dimensiones; y (3) en el espacio PCA el supuesto de independencia de Naive Bayes es una aproximación más cercana a la realidad, al estar las componentes decorrelacionadas por construcción.

Se retuvo el número mínimo de componentes que acumulan el 90% de la varianza explicada (K_{opt} componentes), verificando que $n_{ckd} \gg K_{opt}^2$ para garantizar estimaciones MLE

bien condicionadas. El biplot de la figura n, confirmó que el PC1 actúa como discriminante muy asertivo: las variables hematológicas apuntan hacia los pacientes sanos (derecha) mientras que los marcadores de retención renal apuntan hacia los enfermos (izquierda).




Fig. 2. Biplot PCA — PC1 vs PC2 (varianza total explicada: 52.8%). Las flechas representan los *loadings* de cada variable.

E. Clasificadores Paramétricos

Se implementaron siete clasificadores sobre el espacio PCA con K_{opt} componentes, con división estratificada 80/20, entrenamiento y prueba respectivamente, y validación cruzada estratificada de 5 *folds*.

- **Bayes Caso I:** frontera lineal basada en distancia euclidiana.
- **Bayes Caso II / LDA:** matriz de covarianza agrupada, frontera lineal óptima bajo homocedasticidad.
- **QDA (Caso III):** matrices distintas por clase; frontera cuadrática sin restricciones.
- **Discriminante de Fisher (manual):** maximización del criterio de Rayleigh.
- **Naive Bayes Gaussiano:** independencia condicional entre características.
- **Regresión Logística:** modelo discriminativo lineal con función sigmoide.
- **Mínimos Cuadrados:** clasificador lineal base que minimiza el error cuadrático medio.

Los parámetros $\hat{\mu}_i$ y $\hat{\Sigma}_i$ se estimaron por MLE sobre el conjunto de entrenamiento.

F. Clasificadores No Paramétricos

Para los métodos no paramétricos se trabajó sobre variables originales en lugar del espacio PCA, preservando la interpretabilidad clínica directa, considerando que estos modelos poseen mayor poder discriminante. El espacio de trabajo varió según el método: Parzen operó sobre las 5 variables de mayor FDR (*hemo*, *pcv*, *rbcc*, *sc*, *bu*) para evitar problemas con la dimensionalidad, mientras que k-NN, SVM-RBF y MLP utilizaron el espacio de 18 variables clave seleccionadas combinando el FDR de la Fase I con el análisis bivariado (numéricas: *hemo*, *pcv*, *rbcc*, *sc*, *bu*, *sod*, *bgr*, *age*, *bp*;

categorías codificadas: htn, dm, rbc, pc, appet, pe, ane; ordinales: al, su).

1) *Ventanas de Parzen*: Se estimó la densidad de cada clase con un kernel gaussiano restringido a las 5 variables. El parámetro de suavizado se seleccionó mediante la regla de Scott.

2) *K Vecinos más Cercanos*: Se evaluó k-NN con pesos por distancia inversa. El valor óptimo K_{opt} se seleccionó en el rango $k \in \{1, 3, 5, 7, 9, 11, 13, 15\}$ maximizando el AUC-ROC en validación cruzada CV-5.

3) *SVM con Kernel RBF*: Se compararon kernel lineal y RBF. Los hiperparámetros (C, γ) se optimizaron con *Grid Search* y CV-5.

4) *Perceptrón Multicapa (MLP)*: Se evaluaron arquitecturas con activación ReLU, optimizador Adam y regularización L2 ($\alpha = 10^{-4}$), seleccionando la de mayor AUC-CV5. Se aplicó *early stopping* para prevenir sobreajuste. La importancia de variables se cuantificó con *permutation importance*.

III. RESULTADOS Y DISCUSIÓN

A. Clasificadores Paramétricos

La tabla I resume las métricas de los siete clasificadores evaluados sobre el espacio PCA con $K_{opt} = 7$ componentes (90.8% de varianza retenida), split 80/20.

TABLE I
CLASIFICADORES PARAMÉTRICOS (TEST 20%, ESPACIO PCA)

Modelo	Accuracy	F1	AUC	AUC CV-5
QDA (Caso III)	0.9375	0.9485	0.9700	0.9816 ± 0.0128
Regresión Logística	0.9000	0.9200	0.9647	0.9812 ± 0.0046
Naive Bayes	0.9000	0.9200	0.9620	0.9765 ± 0.0103
Bayes Caso II / LDA	0.8750	0.8936	0.9580	0.9784 ± 0.0079
LDA (sklearn)	0.8750	0.8936	0.9580	0.9784 ± 0.0079
Mín. Cuadrados	0.8750	0.8936	0.9580	0.9784 ± 0.0079
Fisher LDA	0.8375	0.8506	0.9580	—
Bayes Caso I	0.8750	0.8889	0.9493	0.9663 ± 0.0104

El QDA alcanzó el mayor AUC del grupo paramétrico (0.9700, CV-5: 0.9816 ± 0.0128), confirmando la predicción central que se realizó en el EDA: la heterocedasticidad $\hat{\Sigma}_{CKD} \neq \hat{\Sigma}_{NOTCKD}$ hace que la frontera cuadrática sea más adecuada que cualquier frontera lineal. Al modelar matrices de covarianza distintas por clase, el QDA adapta la forma de sus isocontornos a la geometría real: una elipse compacta para notCKD y una amplia para CKD. El LDA, al imponer Σ_{pool} , promedió esas geometrías y generó 8 falsos negativos. El Fisher LDA manual, pese a maximizar el criterio de Rayleigh, produjo 13 falsos negativos al usar un umbral empírico en lugar de probabilidades a priori, obteniendo el menor Accuracy del grupo (0.8375).




Fig. 3. Heatmap de métricas (Accuracy, F1, AUC, Sensibilidad, Especificidad) para los clasificadores paramétricos evaluados en el espacio PCA con $K_{opt} = 7$ componentes.

El Naive Bayes superó al LDA en AUC (0.9620 vs 0.9580) gracias a la decorrelación del PCA: al eliminar la multicolinealidad, el supuesto de independencia condicional se aproxima mejor a la realidad, y la diagonal de $\hat{\Sigma}_i$ captura las varianzas distintas por clase de forma parcialmente adecuada. La validación cruzada CV-5 confirmó que todos los resultados son bastante estables: las desviaciones estándar del AUC oscilan entre ± 0.005 y ± 0.013 , sin evidencia de dependencia de la partición.




Fig. 4. Curvas ROC de los clasificadores paramétricos sobre el conjunto de prueba (20%), espacio PCA con $K = 7$ componentes.

B. Clasificadores No Paramétricos

La tabla II resume las métricas de los cinco clasificadores no paramétricos evaluados sobre el espacio de 18 variables clave, con los mismos *splits* estratificados.

TABLE II
CLASIFICADORES NO PARAMÉTRICOS (TEST 20%, VARIABLES CLAVE)

Modelo	Accuracy	F1	AUC	AUC CV-5
SVM Lineal ($C = 1$)	0.9500	0.9583	0.9827	0.9943 ± 0.0060
k-NN ($k = 25$, dist.)	0.9500	0.9583	0.9800	0.9961 ± 0.0038
SVM RBF ($C = 10, \gamma = 1.0$)	0.9625	0.9691	0.9813	0.9953 ± 0.0055
MLP (128, 64, 32)	0.8875	0.9126	0.9747	0.9933 ± 0.0073
Parzen KDE (Top-5 FDR)	0.8500	0.8846	0.9700	0.9891 ± 0.0050

El SVM-RBF ($C = 10, \gamma = 1.0$, optimizado por *Grid Search* CV-5) obtuvo el mayor Accuracy y F1 del proyecto (0.9625 y 0.9691 respectivamente), mientras que el SVM Lineal obtuvo el mayor AUC en test (0.9827). En validación cruzada, el k-NN ($k = 25$, pesos por distancia) alcanzó el mayor AUC-CV5 del proyecto completo (0.9961 ± 0.0038), demostrando una separabilidad muy precisa en el espacio de variables clave. El MLP con arquitectura Deep-3 (128, 64, 32), convergió en apenas 30 épocas gracias al *early stopping* con un AUC CV-5: 0.9933 ± 0.0073 .




Fig. 5. Grid Search AUC-ROC del SVM-RBF en función de los hiperparámetros C y γ (validación cruzada CV-5).

El clasificador Parzen KDE, operando únicamente en las 5 variables de mayor FDR, establece una línea base no paramétrica sólida: en AUC test obtuvo 0.9700, y en CV-5 un 0.9891 ± 0.0050 . Nótese que este valor es idéntico al del mejor clasificador paramétrico (QDA con $AUC = 0.9700$), con la diferencia de que Parzen opera en solo 5 dimensiones sin ningún supuesto distribucional, confirmando que ese subespacio concentra prácticamente toda la información diagnóstica.




Fig. 6. Diagrama de Voronoi (1-NN) y frontera de decisión k-NN proyectada sobre el subespacio hemo-pcv.

C. Importancia de Variables y Consistencia Metodológica

El análisis de importancia por permutación (*Permutation Feature Importance*) del MLP reveló que las cinco variables con mayor ΔAUC son al (0.0359 ± 0.0152), hemo (0.0265 ± 0.0144), sc (0.0148 ± 0.0083), pcv (0.0122 ± 0.0102) y su (0.0102 ± 0.0103). La presencia de hemo, sc y pcv en el top 5 del MLP coincide con la jerarquía del FDR calculado en la Fase I de este proyecto. La aparición de al y su como variables de mayor impacto en el MLP — marcadores ordinales de albúmina y glucosa — es consistente con su rol clínico como indicadores patológicos progresivos del daño glomerular, y también añade matiz frente a ese análisis lineal del FDR.




Fig. 7. Importancia de variables por permutación del MLP; valores más positivos indican mayor relevancia diagnóstica.

D. Comparación Final entre Paradigmas

Todos los métodos no paramétricos superan en AUC test al mejor clasificador paramétrico (QDA, 0.9700) excepto el Parzen KDE que iguala ese valor. La diferencia entre el QDA y el SVM Lineal en AUC test ($0.9827 - 0.9700 = 0.0127$) cuantifica de algún modo el costo de los supuestos distribucionales gaussianos en este problema clínico. En la validación cruzada CV-5, la brecha se amplía: el k-NN alcanza 0.9961 ± 0.0038 frente al 0.9816 ± 0.0128 del QDA, una diferencia de 0.0145 puntos de AUC con menor varianza. Esto confirma que la superioridad no paramétrica es sistemática y no una consecuencia indirecta de aspectos como la partición.

Desde la perspectiva de pérdida asimétrica de Bayes, los métodos no paramétricos también minimizan los falsos negativos de forma más efectiva al no imponer fronteras rígidas sobre distribuciones no gaussianas, reduciendo el riesgo clínico de pacientes con IRC no diagnosticados.




Fig. 8. Heatmap comparativo de métricas (Accuracy, F1, AUC, Sensibilidad, Especificidad) para todos los clasificadores evaluados en el proyecto.

IV. CONCLUSIONES

El análisis comparativo desarrollado a lo largo de tres fases metodológicas progresivas demuestra que el rendimiento de un clasificador en datos clínicos no depende principalmente de su sofisticación algorítmica, sino de qué tan bien sus supuestos se alinean con la estructura real del problema. En el caso de la IRC, esa estructura está dominada por dos características que ningún preprocesamiento elimina: distribuciones fuertemente asimétricas en los marcadores de retención renal y una heterocedasticidad severa entre clases. Los pacientes sanos son fisiológicamente homogéneos — se les concentra en una región compacta del espacio de características — mientras que los pacientes enfermos son heterogéneos: la cascada de desequilibrios metabólicos que produce la IRC los dispersa ampliamente. Imponer supuestos que ignoran esta asimetría no es solo una limitación técnica; es una descripción incorrecta de la realidad clínica.

El QDA representó el límite de lo que los supuestos gaussianos pueden ofrecer: al ser el único modelo paramétrico que respeta la desigualdad de covarianzas, alcanzó el mejor desempeño de su paradigma. Pero incluso ese modelo deja errores en la zona de transición entre clases que una gaussiana, por definición, no puede capturar sin distorsionar la frontera. Los métodos no paramétricos no “mejoran” al QDA por ser más complejos sino que lo superan porque no le imponen a los datos una forma que estos no tienen.

Un resultado que merece atención especial es la convergencia entre el análisis estadístico lineal de la Fase I y el aprendizaje no lineal de la Fase III. El Fisher Discriminant Ratio identificó las mismas variables que el MLP, una red de tres capas entrenada con backpropagation, consideró más informativas al permutar sus valores. Esta coincidencia sugiere que la jerarquía de importancia de los biomarcadores renales es una propiedad intrínseca de la fisiopatología de la enfermedad. La hemoglobina, el volumen celular empacado y la creatinina sérica son discriminantes poderosos no porque algún algoritmo los seleccionó, sino porque el riñón dañado los altera de forma sistemática y medible.

Igualmente relevante es el resultado del clasificador de Parzen sobre el subespacio de cinco variables: alcanzar

un AUC equivalente al mejor modelo paramétrico usando únicamente esas cinco dimensiones y sin ningún supuesto distribucional explica que el poder diagnóstico del dataset no está distribuido uniformemente entre las 24 variables originales. Esta concentración de información tiene implicaciones directas: un panel diagnóstico reducido a hemoglobina, volumen celular empacado, conteo de glóbulos rojos, creatinina sérica y urea podría ser suficiente para una herramienta de tamizaje de alta sensibilidad, reduciendo el costo y la complejidad de la evaluación clínica inicial.

Desde la perspectiva de la teoría de decisión, el resultado más importante es la capacidad de los métodos no paramétricos de minimizar los falsos negativos sin sacrificar especificidad. Un paciente con IRC no diagnosticado no recibe tratamiento durante la ventana de tiempo en que la intervención puede ralentizar el deterioro renal; el costo humano de ese error es incomparablemente mayor que el de una derivación innecesaria a nefrología. Los métodos que no imponen fronteras rígidas sobre distribuciones complejas son, en este sentido, no solo más precisos sino más seguros.

Como trabajo futuro, tres extensiones son especialmente motivadas por los hallazgos de este proyecto. Primero, la incorporación explícita de funciones de pérdida asimétrica en el entrenamiento de los clasificadores, penalizando los falsos negativos en proporción al costo clínico real, permitiría alinear el criterio de optimización del modelo con el objetivo médico. Segundo, la validación sobre cohortes de pacientes colombianos es necesaria para evaluar la transferibilidad geográfica y cultural del modelo antes de cualquier aplicación clínica local. Tercero, la exploración de métodos de aprendizaje semi-supervisado que aprovechen la abundancia de datos clínicos no etiquetados disponibles en entornos hospitalarios podría ampliar significativamente la capacidad de generalización sin requerir el costoso proceso de etiquetado por especialistas.

REFERENCES

- [1] R. O. Duda, P. E. Hart, and D. G. Stork, *Pattern Classification*, 2nd ed. New York, NY, USA: Wiley-Interscience, 2001.
- [2] National Kidney Foundation, “KDOQI clinical practice guidelines for chronic kidney disease: Evaluation, classification, and stratification,” *American Journal of Kidney Diseases*, vol. 39, no. 2, suppl. 1, pp. S1–S266, 2002.
- [3] S. S. Shapiro and M. B. Wilk, “An analysis of variance test for normality (complete samples),” *Biometrika*, vol. 52, no. 3/4, pp. 591–611, 1965.
- [4] R. D’Agostino and E. S. Pearson, “Tests for departure from normality: Empirical results for the distributions of b_2 and $\sqrt{b_1}$,” *Biometrika*, vol. 60, no. 3, pp. 613–622, 1973.
- [5] F. J. Massey Jr., “The Kolmogorov-Smirnov test for goodness of fit,” *Journal of the American Statistical Association*, vol. 46, no. 253, pp. 68–78, Mar. 1951.
- [6] D. Dua and C. Graff, “UCI Machine Learning Repository,” University of California, Irvine, School of Information and Computer Sciences, 2019. [Online]. Available: <https://archive.ics.uci.edu/dataset/336/chronic+kidney+disease>
- [7] UCI ML Repository Python Package. [Online]. Available: <https://pypi.org/project/ucimlrepo/>
- [8] Mayo Clinic, “Chronic kidney disease — symptoms and causes,” Mayo Foundation for Medical Education and Research. [Online]. Available: <https://www.mayoclinic.org/es/diseases-conditions/chronic-kidney-disease/symptoms-causes/syc-20354521>
- [9] American Kidney Fund, “Polycystic kidney disease (PKD).” [Online]. Available: <https://www.kidneyfund.org/es/sintomas-tratamiento-y-causas-de-la-poliquistosis-renal>